

COMPONENTE CURRICULAR:	Projeto Aplicado II
GRUPO	Grupo 13
ALUNOS	
Thaís Cristine de Andrade Gomes	10721642
Paulo Ricardo de Oliveira Ramos	10721464
Lucas Iglezias dos Anjos	10433522
Oscar Augusto de Oliveira Luz	10435099

Análise de Sentimentos em Avaliações do Aplicativo Tinder



Sumário

1. Introdução	3
2. Linguagem de Programação	3
3. Análise Exploratória da Base de Dados	4
4. Tratamento da Base de Dados	4
5. Definição dos Métodos Analíticos	5
6. Acurácia e Métricas de Avaliação	6
7. Repositório do Projeto	7

Introdução

Dando continuidade ao desenvolvimento do Projeto Aplicado II, esta segunda etapa tem como foco a definição do método analítico que será utilizado na resolução do problema proposto. O grupo optou por trabalhar com dados textuais reais extraídos da loja de aplicativos Google Play Store, mais especificamente das avaliações feitas por usuários do aplicativo Tinder.

O principal objetivo do projeto é aplicar técnicas de aprendizado de máquina para identificar o sentimento presente nos comentários textuais, classificando-os como positivos, negativos ou neutros. Para isso, são necessárias diversas etapas, como análise exploratória da base, tratamento dos dados, escolha do modelo e definição de métricas de avaliação. Esta documentação apresenta o detalhamento de cada uma dessas etapas, com justificativas teóricas e práticas, alinhadas com os objetivos do curso e da disciplina.

Linguagem de Programação

A linguagem de programação escolhida para o desenvolvimento deste projeto foi o Python, que é amplamente adotada no campo da Ciência de Dados e do aprendizado de máquina. A escolha se justifica por diversos fatores: facilidade de leitura, comunidade ativa, e principalmente pela robustez de seu ecossistema de bibliotecas específicas para manipulação de dados, processamento de linguagem natural e modelagem estatística. As bibliotecas utilizadas incluem:

- `pandas` e `numpy` para manipulação de dados e estruturas tabulares;
- `matplotlib` e `seaborn` para visualização gráfica e análise exploratória;
- `nltk` para o pré-processamento de textos, como remoção de stopwords e tokenização;
- `scikit-learn` para vetorização dos dados e implementação do modelo de aprendizado supervisionado;
- `pickle` para armazenamento de vetores e rótulos após processamento.

A escolha dessa stack permitiu maior flexibilidade e eficiência no desenvolvimento colaborativo do projeto.

Análise Exploratória da Base de Dados

A base de dados analisada é composta por 676.014 registros de avaliações deixadas por usuários do aplicativo Tinder na loja Google Play Store. Cada entrada inclui campos como o texto da avaliação (review), a nota atribuída (rating) e a data da publicação (review_date). A fonte dos dados é pública e foi obtida através da plataforma Kaggle.

Durante a análise exploratória, observou-se uma forte polarização nas notas atribuídas pelos usuários: a maior parte dos registros se concentra nas pontuações mais baixas (1 estrela) e mais altas (5 estrelas). Esse padrão indica que os usuários tendem a se manifestar mais quando estão muito satisfeitos ou extremamente insatisfeitos com o serviço.

O grupo analisou também a distribuição dos textos ao longo do tempo, verificando tendências e possíveis sazonalidades. Além disso, foi realizada a contagem de frequência das palavras mais comuns em cada faixa de sentimento, por meio de nuvens de palavras (wordclouds) e histogramas. Por exemplo, termos como “erro”, “bug” e “pago” aparecem com alta frequência em avaliações negativas, enquanto palavras como “ótimo”, “match” e “legal” são recorrentes nos comentários positivos.

Valores ausentes foram identificados e tratados. A coluna de resposta da empresa (reply) foi ignorada, pois o foco da análise está no texto do usuário. A análise exploratória também permitiu identificar a necessidade de transformar os dados em classes categóricas para facilitar o treinamento supervisionado.

Tratamento da Base de Dados

A base passou por um processo detalhado de tratamento e preparação para garantir que os dados estivessem adequados ao modelo de aprendizado de máquina. As etapas de pré-processamento incluíram:

- I. **Limpeza textual:** remoção de caracteres especiais, números, pontuações, emojis e outros elementos não relevantes para a tarefa de classificação.
- II. **Normalização:** transformação de todo o texto para caixa baixa (lowercase) para padronização.
- III. **Remoção de stopwords:** uso do pacote `nltk` para eliminar palavras de baixo valor semântico, como preposições e artigos.

IV. **Tokenização e lematização:** ainda que não utilizadas em todas as etapas, essas técnicas foram consideradas para cenários mais robustos.

Após a limpeza, os dados foram classificados em três categorias com base na nota atribuída pelo usuário:

- Negativa: notas de 1 e 2
- Neutra: nota 3
- Positiva: notas 4 e 5

Esse critério permitiu uma divisão mais realista dos sentimentos, evitando extremos e considerando também avaliações intermediárias.

Na etapa seguinte, os textos foram convertidos em representações numéricas usando o vetorizador TF-IDF (Term Frequency-Inverse Document Frequency), que avalia a relevância das palavras dentro do conjunto de documentos. Essa técnica foi escolhida por ser leve, eficiente e adequada para modelos lineares como o Naive Bayes.

Por fim, a base foi dividida em dois conjuntos:

- 80% para treino (X_train, y_train)
- 20% para teste (X_test, y_test)

Os arquivos gerados foram armazenados e versionados no repositório do projeto para reutilização futura.

Definição dos Métodos Analíticos

4.1 Fundamentação Teórica

O modelo selecionado para aplicação foi o Multinomial Naive Bayes, que é uma variação do algoritmo Naive Bayes voltada para problemas de classificação de texto e documentos.

O Naive Bayes é um classificador probabilístico baseado no Teorema de Bayes, com uma suposição de independência entre as características (neste caso, as palavras dos textos). A fórmula geral é:

$$P(C | X) = (P(X | C) * P(C)) / P(X)$$

Onde:

- $P(C | X)$ é a probabilidade de a classe C ser atribuída ao texto X;
- $P(X | C)$ é a probabilidade de o texto X ser gerado pela classe C;
- $P(C)$ é a probabilidade de ocorrência da classe C;
- $P(X)$ é a probabilidade geral do texto.

Apesar da suposição simplificadora de independência entre palavras, esse modelo apresenta bons resultados práticos em tarefas de classificação de sentimento, especialmente quando os dados estão bem preparados e vetorizados por TF-IDF.

4.2 Justificativa da Escolha

A escolha do Naive Bayes para este projeto se justifica por:

- Algoritmo simples, rápido e eficiente, mesmo em bases grandes.
- Pouca necessidade de ajuste de hiperparâmetros.
- Interpretável e com bom desempenho para texto curto.

A implementação foi feita com o módulo `MultinomialNB` da biblioteca `scikit-learn`.

Acurácia e Métricas de Avaliação

Para avaliar o desempenho do modelo, o grupo optou por aplicar três métricas principais:

1. **Acurácia:** mede a proporção de classificações corretas em relação ao total de exemplos. É uma métrica global, útil para ter uma visão geral da performance.
2. **F1-Score (Macro):** considera o equilíbrio entre precisão e recall em cada uma das classes, e calcula a média entre elas. Essa métrica é especialmente útil quando as classes estão desbalanceadas, como é o caso aqui.
3. **Matriz de Confusão:** permite visualizar de forma detalhada a distribuição dos acertos e erros do modelo para cada categoria. Com ela é possível verificar, por exemplo, se o modelo está confundindo avaliações neutras com positivas.

Essas métricas foram escolhidas por fornecerem uma análise mais completa do desempenho do classificador, indo além da simples acurácia e ajudando a entender o comportamento do modelo diante de um problema multiclasse.



Repositório do Projeto

Todos os arquivos do projeto, incluindo scripts Python, notebooks, bases de dados originais e tratadas, vetores vetorizados e modelos treinados estão disponíveis de forma organizada no seguinte link: <https://github.com/lcsigzs/Projeto-Aplicado-II>.