

COMPONENTE CURRICULAR:	Projeto Aplicado II
GRUPO	Grupo 13
ALUNOS	
Thaís Cristine de Andrade Gomes	10721642
Paulo Ricardo de Oliveira Ramos	10721464
Lucas Iglezias dos Anjos	10433522
Oscar Augusto de Oliveira Luz	10435099

Relatório Técnico



Sumário

1. Introdução	3
2. Etapas do Projeto	3
3. Metodologia	4
4. Medidas de Acurácia	5
5. Storytelling	5
6. Objetivos Atendidos	6
7. Repositório do Projeto	6
8. Vídeo da Apresentação	7
9. Conclusão	7

Introdução

Este relatório apresenta a conclusão do Projeto Aplicado II, que teve como objetivo desenvolver um classificador de sentimentos baseado em textos de avaliações de usuários do aplicativo Tinder, coletadas da Google Play Store. O projeto foi construído ao longo do semestre e dividido em quatro etapas principais, envolvendo a definição do problema, análise exploratória, construção e avaliação do modelo, além da apresentação final dos resultados por meio da técnica de Data Storytelling.

As decisões tomadas em cada fase do projeto foram fundamentadas nos conteúdos das disciplinas cursadas neste semestre, como Aprendizado de Máquina I, Análise Estatística Preditiva e Aquisição e Preparação de Dados. Nesta etapa final, consolidamos todas as fases anteriores, revisamos os pontos levantados pelo professor e organizamos os produtos gerados, incluindo o repositório no GitHub e o vídeo da apresentação do projeto.

Etapas do Projeto

- Etapa 1 – Definição da Proposta

O grupo escolheu trabalhar com dados públicos relacionados ao aplicativo Tinder, uma empresa da área de tecnologia voltada à conexão entre pessoas. A base de dados utilizada contém mais de 670 mil avaliações coletadas da Google Play Store. As avaliações, em formato textual, foram utilizadas como entrada para um modelo de aprendizado de máquina com o objetivo de classificar automaticamente o sentimento do usuário. Foram definidos os seguintes objetivos:

- Categorizar os sentimentos expressos nas avaliações de usuários do Tinder.
- Desenvolver um modelo preditivo que automatize essa tarefa.
- Apresentar os resultados obtidos de forma clara e estruturada.

A base foi previamente tratada e amostrada para facilitar o desenvolvimento, e o cronograma foi dividido em 4 etapas mensais com entregas intermediárias.

- Etapa 2 – Preparação dos Dados e Escolha do Modelo

O grupo optou por trabalhar com Python como linguagem principal, utilizando bibliotecas como `pandas`, `sklearn`, `seaborn`, `nlTK` e `pickle`. A base de dados passou por diversas etapas de limpeza, categorização de sentimentos (de 1 a 5) com base nas notas das avaliações, e vetorização com TF-IDF.

Para o modelo, foi escolhido o algoritmo Multinomial Naive Bayes, por ser amplamente utilizado em problemas de classificação de texto. Ele foi treinado e validado com uma divisão de treino/teste a partir da base processada. As métricas iniciais indicaram um bom desempenho para sentimentos extremos, com maior dificuldade para classes intermediárias.

- **Etapas 3 – Aplicação, Resultados e Produto Gerado**

O modelo foi aplicado à base vetorizada e apresentou os seguintes resultados:

- Acurácia: 67%
- F1-score: 0.34

Apesar da acurácia considerada baixa para um problema com 5 classes, o modelo se mostrou funcional e coerente com o tipo de dado utilizado. O grupo reconheceu as limitações e sugeriu possíveis melhorias, como agrupar as avaliações em apenas 3 classes (negativo, neutro e positivo) ou utilizar modelos mais robustos.

O produto gerado foi um sistema de classificação de sentimento com entrada textual e saída preditiva baseada na nota esperada (de 1 a 5). Esse classificador pode ser integrado a processos internos de empresas para automatizar a leitura e interpretação de grandes volumes de avaliações.

Metodologia

A metodologia adotada seguiu os princípios do CRISP-DM, contemplando as etapas de entendimento do negócio, preparação dos dados, modelagem, avaliação e apresentação. Todas as decisões metodológicas foram orientadas pelos conteúdos desenvolvidos nas disciplinas do semestre.

Para a fase de modelagem, foi utilizado o algoritmo Multinomial Naive Bayes, por ser apropriado para tarefas de classificação de texto. O modelo foi treinado a partir de dados vetorizados com a técnica TF-IDF, o que possibilitou uma representação eficaz dos comentários textuais. A escolha do Naive Bayes também se deu por sua simplicidade, eficiência e capacidade de lidar bem com problemas de classificação de múltiplas classes.

A performance do modelo foi avaliada por meio de métricas como acurácia, precisão, recall e F1-score, considerando principalmente os desafios em diferenciar as classes intermediárias. Após ajustes no número de categorias, foi possível obter resultados mais consistentes, que contribuíram para uma análise mais clara da percepção dos usuários.

Medidas de Acurácia

Inicialmente, o modelo foi treinado com 5 classes (notas de 1 a 5), atingindo os seguintes resultados:

- **Acurácia geral:** 67,76%
- **F1-score ponderado:** 0,59
- **F1-score médio geral:** 0,34

A performance foi satisfatória para as classes extremas (Muito Positiva e Muito Negativa), mas fraca nas classes intermediárias (Neutra, Negativa e Positiva), conforme identificado também na matriz de confusão.

Com base no feedback do professor e na análise crítica do grupo, reformulamos o problema de classificação para um cenário binário, agrupando as notas em duas classes:

1. Negativa (1 a 3)
2. Positiva (4 e 5)

Essa nova abordagem apresentou resultados significativamente superiores:

- **Acurácia geral:** 86,12%
- **F1-score médio:** 0,86

A mudança tornou o modelo mais estável, com melhor balanceamento entre as classes e maior confiabilidade para a tarefa de análise de sentimentos. A reformulação também está alinhada à proposta prática do projeto, permitindo uso mais direto em aplicações reais com classificação binária de satisfação.

Storytelling

A apresentação final foi construída com base nos princípios do Data Storytelling, buscando uma narrativa clara, envolvente e alinhada com os dados obtidos. O roteiro da apresentação segue a seguinte estrutura:

- I. **Introdução ao problema:** a importância de entender o sentimento dos usuários sobre aplicativos.
- II. **Proposta do projeto:** como o Tinder foi escolhido e qual o objetivo da análise.
- III. **Etapas do projeto:** explicação do pipeline de dados, categorização, modelo e resultados.
- IV. **Produto gerado:** como o classificador pode ser utilizado na prática.

V. **Resultados e próximos passos:** apresentação das métricas e sugestões de melhoria.

Os slides foram criados de forma visual e objetiva, com gráficos, trechos de código e exemplos reais extraídos da base de dados. A apresentação será gravada em vídeo e publicada no YouTube.

Objetivos Atendidos

O projeto alcançou os principais objetivos definidos no início do semestre, entre eles:

- Aplicação prática da análise de sentimentos em dados textuais, por meio da coleta e modelagem de avaliações reais de usuários sobre o aplicativo Tinder.
- Execução de um fluxo completo de ciência de dados, desde a aquisição, limpeza e preparação dos dados até a categorização e vetorização textual.
- Aplicação de técnicas de aprendizado de máquina supervisionado, com o uso do algoritmo Naive Bayes para classificar os sentimentos expressos nas avaliações.
- Avaliação das métricas de desempenho, inicialmente com um modelo de 5 classes, posteriormente reformulado para 2 classes para melhorar a acurácia e o F1-score.
- Criação de um Storytelling estruturado, com foco em comunicar de forma clara os insights obtidos e o valor do modelo gerado.
- Trabalho colaborativo com versionamento de código, repositório no GitHub e produção conjunta do relatório e da apresentação.

Os resultados demonstram a evolução do grupo na aplicação dos conhecimentos adquiridos ao longo dos componentes curriculares, com entregas organizadas e tecnicamente consistentes.

Repositório do Projeto

Todos os arquivos do projeto estão disponíveis em um repositório público do GitHub, contendo:

- Dataset original e versões tratadas
- Scripts de análise exploratória e pré-processamento
- Código do modelo Naive Bayes

- Vetorizadores e dados de treino/teste em formato .pkl
- Arquivo de requisitos e instruções de execução

O repositório foi organizado em pastas nomeadas por etapa e devidamente documentado no README principal, com orientações claras para reprodução do projeto, no seguinte link: <https://github.com/lcsigzs/Projeto-Aplicado-II>.

Vídeo da Apresentação

A gravação da apresentação final foi feita de forma colaborativa seguindo o mesmo roteiro do storytelling apresentado nos slides. Cada integrante gravou sua parte e o material foi editado por um membro do grupo, que ficou responsável por juntar os trechos e publicar o vídeo no YouTube. O link da apresentação está disponível no README do repositório GitHub.

Conclusão

O desenvolvimento deste projeto permitiu aplicar conceitos de ciência de dados em um cenário realista, utilizando uma base textual composta por avaliações de usuários sobre o aplicativo Tinder. Ao longo das etapas, realizamos desde a aquisição, limpeza e preparação dos dados até a aplicação de modelos de aprendizado de máquina, com foco na análise de sentimentos.

Na primeira versão do modelo, optamos por classificar os sentimentos em cinco categorias distintas, representando os níveis de avaliação de 1 a 5. Embora essa abordagem tenha apresentado desempenho razoável nas classes extremas, o modelo demonstrou baixa capacidade de distinção entre as classes intermediárias, o que impactou negativamente as métricas de desempenho.

Com base no feedback recebido, reavaliamos nossa estratégia e reformulamos o problema como uma tarefa de classificação binária (positivo e negativo). Essa mudança resultou em uma melhoria significativa da acurácia e do F1-score, tornando o modelo mais robusto, simples e eficaz para aplicações práticas. O projeto demonstrou, portanto, a importância de avaliar não apenas os resultados quantitativos, mas também a coerência entre o modelo e os objetivos analíticos do negócio.